



Título:

***Análise Regional de Segurança Pública:
Modelo de Regressão Linear Aplicado ao
Furto e Recuperação de Veículos no
Estado do Rio de Janeiro.***

Subtítulo:

Estudo Comparativo acerca dos furtos e recuperação de veículos entre Capital, Baixada Fluminense, Grande Niterói e Interior do estado do Rio de Janeiro.

Professora: Simone Gama.

Curso: Análise e Desenvolvimento de Sistemas.

Instituição: Estácio de Sá.

Participantes: *Thiago Marlon da Conceição Esteves Damas, número de matrícula (202502432968), Gabriel Araújo dos Santos Pereira, número de matrícula (202504255079).*

Introdução:

Problemática: O roubo e furto de veículos representam um dos maiores gargalos da segurança pública fluminense. Compreender a eficiência do Estado em reaver esses bens é essencial. A taxa de recuperação acompanha proporcionalmente o volume de crimes ou existem disparidades regionais?

Solução Apresentada: Desenvolvimento de um modelo preditivo baseado em **Regressão Linear Simples** segregado por 4 macrorregiões para medir o impacto de um furto incremental na capacidade de recuperação policial.

Impacto Social: Subsidiar o planejamento estratégico das polícias Civil e Militar, identificando quais regiões demandam maior aporte logístico ou reestruturação de delegacias especializadas (como a DRFA).

Objetivos Geral e Específicos:

Objetivo Geral:

Analisar a relação estatística entre o volume de furtos de veículos e a sua respectiva recuperação nas diferentes regiões do estado do Rio de Janeiro utilizando ciência de dados.

Objetivos Específicos:

Mapear e segregar os dados criminais mensais com base nos dados do **ISP – Instituto de Segurança Pública** (*Capital, Baixada Fluminense, Interior e Grande Niterói*).

Implementar modelos de regressão linear simples para cada ecossistema regional.

Avaliar e comparar a precisão dos modelos através das métricas estatísticas.

Ferramentas Usadas:

O projeto foi inteiramente estruturado em ambiente de desktop utilizando a linguagem Python. As principais bibliotecas aplicadas foram:

VSCODE - Jupiter notebook Python: Ambiente de desenvolvimento integrado para computação Desktop.

Pandas & NumPy: Manipulação, filtragem de registros por região e tratamento matemático dos arrays.

Scikit-Learn (LinearRegression): Algoritmo responsável por computar os coeficientes e ajustar as retas pelo método dos mínimos quadrados e aprendizado de máquina.

Matplotlib: Geração dos gráficos de dispersão unificados em um painel para análise visual.

Base de Dados:

Origem dos Dados: Dados oficiais provenientes do Instituto de Segurança Pública (ISP) do Rio de Janeiro (<https://www.ispdados.rj.gov.br/estatistica.html>)

(arquivo - BaseDPEvolucaoMensalCisp.csv).

(Tamanho do arquivo – 6,66 MB)

Observação: Os dados estavam bem estruturados e não foi necessário um forte tratamento na base, apenas algumas correções pontuais, para que a análise tivesse uma forte coesão assertiva.

Estrutura e Variáveis: O volume de linhas reflete o histórico mensal consolidado por Circunscrição Integrada de Segurança Pública (CISP). As variáveis chave analisadas foram furto_veiculos (Variável Dependente Y), recuperacao_veiculos (Variável Dependente Y) e Ano (Variável Independente X).

Tratamento de Dados: Foi aplicado um tratamento cirúrgico focado na consistência estatística, eliminamos quaisquer registros nulos ou ausentes dessas colunas para evitar viés nas inclinações das retas.

Análise Crítica dos Resultados:

Análise Descritiva da Base de Dados:

O que foi feito: Antes de criar qualquer modelo preditivo, foi feita uma exploração estatística descritiva para entender o comportamento geral e a escala dos crimes em cada região do estado do Rio de Janeiro.

Métricas analisadas: Foram calculados as médias e os desvios padrões mensais das variáveis dependentes

Furtos de Veículos (Y), Recuperação de Veículos (Y) e a variável ano como variável independente (X).

Interpretação Prática: As regiões da Capital e a Baixada Fluminense apresentam as maiores médias mensais de furtos e recuperações, refletindo a alta densidade populacional e de frota circulante, já as regiões do Interior e da Grande Niterói possuem volumes significativamente menores, o que muda a dinâmica de comportamento dos dados. O desvio padrão nos mostra o quanto o crime oscila mês a mês (se há meses com picos muito discrepantes ou se o crime mantém uma linha constante).

Regressão Linear Simples:

O que foi feito: O objetivo do trabalho foi modelar o impacto que o aumento de furtos causa na capacidade de resposta da polícia (recuperação). Foi criada uma reta matemática para cada uma das 4 regiões.

Coeficiente Angular: Ele explica a taxa de conversão da polícia. Se o coeficiente angular da Capital for, por exemplo, 0.45, significa que a cada 100 veículos furtados a mais em um mês, a polícia recupera em média estatisticamente 45 veículos adicionais.

Intercepto: Conforme mapeado no código, em algumas regiões ele apresentará comportamento negativo ou flutuante. O intercepto aqui atua como constante de ajuste matemático, dado que o cenário de "zero furtos" é uma extrapolação fora do domínio de dados históricos.

Força do Modelo (Ajuste): regiões com $(R^2) \geq 0.7$ validam que a atividade de recuperação é estritamente vinculada ao volume de ocorrências (Ajuste Forte). Regiões com (R^2) baixo indicam que o modelo simples não basta: fatores externos (como desmanches interestaduais ou policiamento de fronteira) interferem no ritmo das recuperações.

Distribuição de Frequências:

O que foi feito: Foi analisado como os volumes mensais de furtos se espalham ao longo do tempo. Em vez de olhar apenas para a média, a distribuição de frequências divide os dados em faixas (por exemplo: meses com 0 a 100 furtos, 101 a 200 furtos, etc.) para ver em qual faixa os meses se concentram mais.

Interpretação Prática: Permite identificar se a criminalidade em uma região é estável ou sazonal. Se

uma região tem a maioria dos meses concentrada em uma faixa estreita de valores, o comportamento do crime é previsível. Se a distribuição for muito espalhada (especialmente em regiões menores como o Interior ou Grande Niterói), significa que o comportamento é mais volátil, dificultando a precisão de um modelo de regressão linear simples.

Identificação de Outliers (Pontos Fora da Curva):

O que foi feito: Na análise visual dos gráficos gerados pelo nosso código (os pontos azuis dispersos ao redor da linha vermelha), procuramos por outliers — meses atípicos em que o volume de furtos ou de recuperações foi absurdamente maior ou menor que o normal histórico.

Interpretação Prática:

Outlier de Furto: Um mês com um pico histórico de crimes (pode indicar uma onda de criminalidade específica, grandes eventos públicos na região ou greve de forças de segurança).

Outlier de Recuperação: Um mês onde a recuperação foi muito maior do que a linha de tendência previa. Na prática da segurança pública, isso costuma indicar o sucesso de grandes operações policiais, estouro de desmanches clandestinos ou a desarticulação de quadrilhas especializadas naquela região.

identificar esses pontos é fundamental, pois outliers extremos têm o poder de "puxar" a linha da regressão para cima ou para baixo, distorcendo os dados analisados.

Análise Final:

"Nosso trabalho realizou uma Análise Descritiva (para compreender o histórico e distribuição dos dados através das médias e frequências) combinada com uma Análise Preditiva (onde usamos a Regressão Linear Simples para tentar estimar a capacidade futura de recuperação de veículos com base na tendência dos furtos registrados)."

Conclusão da Implementação: O modelo de regressão linear dividida provou que a segurança pública no Rio de Janeiro não funciona de forma homogênea. O índice

de recuperação responde de maneiras distintas ao volume de criminalidade a depender da região.

Recomendação: Para regiões com ajuste fraco (R^2 baixo), recomenda-se uma abordagem preditiva multivariada em trabalhos futuros, incluindo variáveis como efetivo policial, malha rodoviária e índices socioeconômicos locais.

Considerações finais: Mudanças de governo, pandemia global, crise financeira do Estado e fatores que estão além de dados estatísticos influenciam diretamente no resultado da análise e estão fora do escopo de controle para serem incluídos estatisticamente.